

人工智能与社会课程

大作业中期报告

基于 Casevo 框架的智能体决策能力优化研究

小组成员： 王宇东（组长）、陈文远

提交日期： 2025 年 12 月 7 日

摘要

本中期报告总结了“基于 Casevo 框架的智能体决策能力优化研究”项目的当前进展。截至目前，我们已完成四个核心优化模块的开发，包括增强型思维链、高级记忆管理、协同决策和决策评估模块，并成功运行了选举投票、资源分配和信息传播三个实验场景的完整对比实验。

实验结果表明，在选举模拟场景中，gpt-4o 模型以 51.5% 的 Biden 支持率几乎完美复现了 2020 年美国大选结果（实际为 51.3%），偏差仅为 0.2%。在推理机制对比实验中，Tree of Thought（ToT）相比 Chain of Thought（CoT）在中间派选民的决策一致性上提升了 10%。此外，LLM 驱动的资源分配协商产生了更公平的分配方案，基尼系数相比规则型基线降低了 9.4%。本报告详细记录了系统实现细节、实验配置和结果分析。

关键词： 大语言模型；多智能体系统；社会模拟；思维链；决策优化

目录

| | |
|-----------------------------------|-----------|
| 1 项目概述 | 3 |
| 1.1 研究目标 | 3 |
| 1.2 总体进度 | 3 |
| 2 系统实现 | 3 |
| 2.1 系统架构 | 3 |
| 2.2 模块开发完成情况 | 4 |
| 2.3 Tree of Thought 实现 | 5 |
| 2.4 高级记忆系统 | 5 |
| 2.5 Prompt 模板 | 5 |
| 2.6 核心代码示例 | 6 |
| 3 实验设计与结果 | 7 |
| 3.1 实验场景概述 | 7 |
| 3.2 实验一：选举投票模拟 | 7 |
| 3.2.1 实验配置 | 7 |
| 3.2.2 实验结果 | 8 |
| 3.2.3 投票演变过程 | 8 |
| 3.3 实验二：CoT vs ToT 推理对比 | 9 |
| 3.3.1 实验配置 | 9 |
| 3.3.2 实验结果 | 10 |
| 3.4 实验三：资源分配协商 | 10 |
| 3.4.1 实验配置 | 10 |
| 3.4.2 实验结果 | 11 |
| 3.5 实验四：信息传播与判断 | 12 |
| 3.5.1 实验配置 | 12 |
| 3.5.2 实验结果 | 12 |
| 3.6 案例分析：智能体推理过程 | 12 |
| 4 与 Proposal 对照分析 | 13 |
| 4.1 完成度对照 | 13 |
| 4.2 偏差与调整 | 14 |
| 5 主要发现与结论 | 14 |
| 5.1 核心发现 | 14 |

| | |
|---------------------|-----------|
| 5.2 待解决问题 | 14 |
| 6 下一步计划 | 14 |

1 项目概述

1.1 研究目标

本项目旨在对 Casevo (Cognitive Agents and Social Evolution Simulator) 框架进行系统性优化，提升智能体在复杂社会模拟场景中的决策质量和适应性。研究聚焦于四个核心优化方向：首先，在推理机制层面，将原有的线性思维链 (Chain of Thought, CoT) 扩展为树状思维 (Tree of Thought, ToT)，支持多路径探索和分支评估；其次，在记忆管理层面，引入上下文感知检索、时间衰减权重和智能遗忘机制，提升记忆检索的相关性；第三，在反思机制层面，设计基于置信度的自适应反思触发策略，使智能体能够在决策不确定时主动进行深度思考；最后，在协同决策层面，构建支持分布式协商和集中式聚合的多智能体决策框架。

1.2 总体进度

表 1: 项目进度总览

| 阶段 | 任务 | 计划周次 | 完成度 |
|------|-----------|-----------|------|
| 第一阶段 | 文献调研与方案设计 | 第 6–7 周 | 100% |
| 第二阶段 | 核心模块开发 | 第 8–11 周 | 100% |
| 第三阶段 | 实验设计与数据采集 | 第 12–14 周 | 80% |
| 第四阶段 | 对比实验与分析 | 第 15–16 周 | 进行中 |
| 第五阶段 | 报告撰写 | 第 17 周 | 待开始 |

2 系统实现

2.1 系统架构

图 1 展示了优化后的 Casevo 框架整体架构，包含四个核心优化模块及其交互关系。

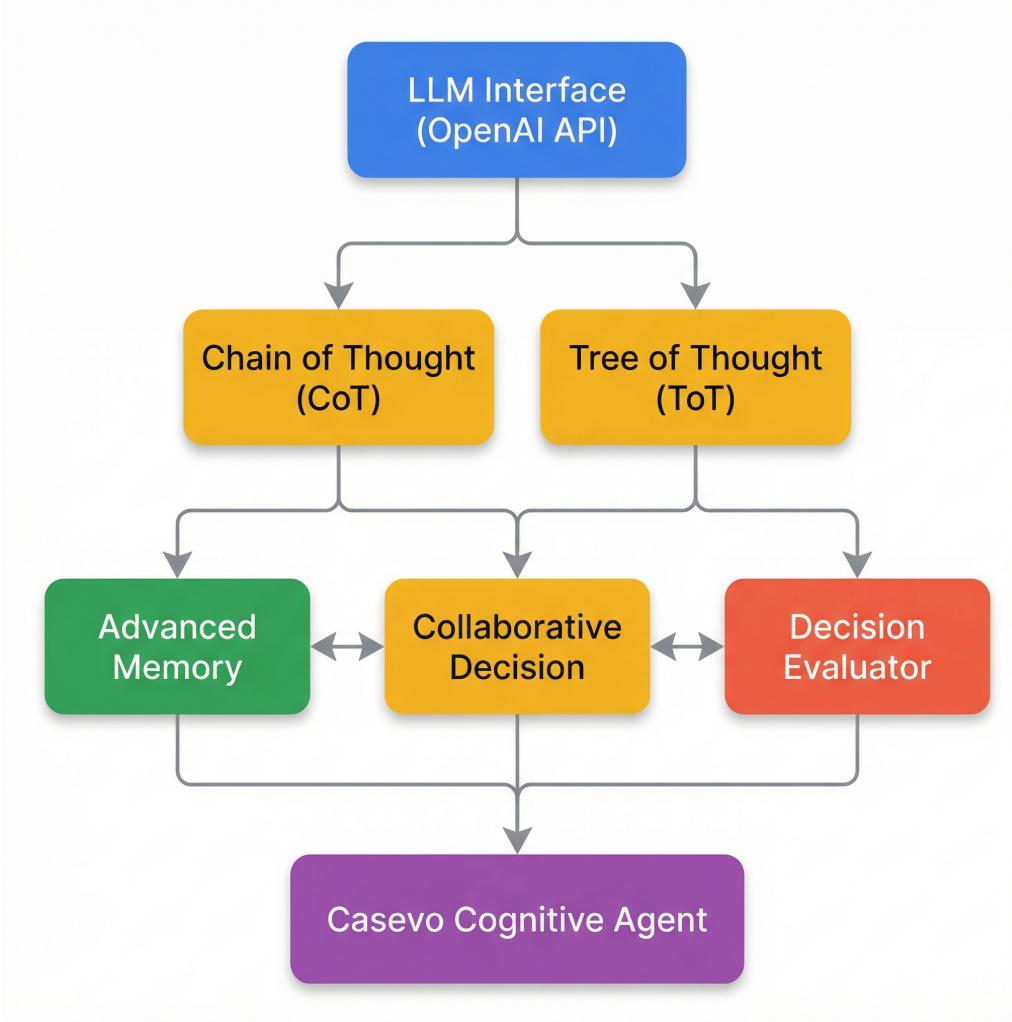


图 1: 优化后的 Casevo 框架架构图

2.2 模块开发完成情况

根据 Proposal 的技术路线，我们已完成以下核心模块的开发：

表 2: 核心模块开发状态

| 模块名称 | 文件路径 | 状态 |
|---------------|--|------|
| 增强型思维链 (ToT) | <code>enhanced_chain.py</code> | ✓ 完成 |
| 高级记忆管理 | <code>advanced_memory.py</code> | ✓ 完成 |
| 协同决策框架 | <code>collaborative_decision.py</code> | ✓ 完成 |
| 决策质量评估 | <code>decision_evaluator.py</code> | ✓ 完成 |
| OpenAI LLM 接口 | <code>llm_openai.py</code> | ✓ 完成 |

注：所有模块位于 `src/casevo/` 目录下

2.3 Tree of Thought 实现

树状思维模块的设计目标是支持多路径探索和分支评估，其实现包含四个核心类。`ToTNode` 类作为思维树的基本节点，负责存储当前路径的状态信息和累积评分。`ToTStep` 类实现分支生成逻辑，在每个决策点调用 LLM 生成多个候选思维路径。`EvaluatorStep` 类负责评估各分支的质量并执行剪枝操作，保留最具潜力的探索方向。`TreeOfThought` 类作为顶层控制器，整合上述组件，实现完整的探索、评估和回溯流程。

2.4 高级记忆系统

记忆系统的优化涵盖四个关键特性。在时间衰减机制方面，记忆的重要性权重随时间推移呈指数衰减，其数学表达式为 $w(t) = e^{-\lambda(t_{now}-t_{create})}$ ，其中 λ 为衰减系数， t_{now} 和 t_{create} 分别表示当前时间和记忆创建时间。在检索策略方面，系统采用上下文感知检索机制，综合考虑语义相似度、时间相关性和情境匹配度三个维度进行记忆召回。此外，系统实现了智能遗忘功能，当记忆数量超过预设阈值时，自动识别并删除低重要性记忆，以维持记忆库的高效运作。最后，记忆压缩机制能够自动合并语义相似的记忆条目，有效减少存储冗余。

2.5 Prompt 模板

为支持各种决策场景，我们设计了以下 Jinja2 模板：

表 3: Prompt 模板列表

| 模板文件 | 用途 |
|--------------------|--------------------------|
| tot_generate.j2 | ToT 分支生成，要求 LLM 输出多个候选方案 |
| tot_evaluate.j2 | ToT 分支评估，对候选方案进行打分 |
| reflect_dynamic.j2 | 动态反思，基于置信度触发深度思考 |
| negotiate.j2 | 多智能体协商，生成协商策略和立场调整 |

2.6 核心代码示例

以下展示 Tree of Thought 模块的核心实现逻辑：

Listing 1: ToT 分支生成与评估核心代码

```

1 class TreeOfThought:
2     def __init__(self, llm, max_branches=3, max_depth=3):
3         self.llm = llm
4         self.max_branches = max_branches
5         self.max_depth = max_depth
6
7     def explore(self, question: str, context: dict) -> str:
8         """执行树状思维探索"""
9         root = ToTNode(state=context, depth=0)
10        best_path = self._dfs_explore(root, question)
11        return best_path.final_answer
12
13    def _dfs_explore(self, node: ToTNode, question: str):
14        if node.depth >= self.max_depth:
15            return node
16
17        # 生成多个候选分支
18        branches = self._generate_branches(node, question)
19
20        # 评估并剪枝
21        scored = [(b, self._evaluate(b, question)) for b in branches]
22        scored.sort(key=lambda x: x[1], reverse=True)
23
24        # 递归探索最优分支

```

```
25     best = scored[0][0]
26     return self._dfs_explore(best, question)
```

3 实验设计与结果

3.1 实验场景概述

根据 Proposal 规划，我们设计了三个实验场景：

表 4: 实验场景配置

| 场景 | 智能体数 | 轮次 | 评估指标 |
|------|------|----|---------------|
| 选举投票 | 101 | 6 | 投票分布、与真实选举偏差 |
| 资源分配 | 30 | 4 | 基尼系数、满足率、收敛速度 |
| 信息传播 | 50 | 6 | 判断准确率、虚假信息识别率 |

3.2 实验一：选举投票模拟

3.2.1 实验配置

本实验构建了包含 101 位选民智能体的选举模拟系统。智能体间的社交网络采用 Watts-Strogatz 小世界网络模型，平均度数设置为 4，重连概率为 0.3。选民的政治画像基于 Pew Research Center 的政治类型学研究，涵盖 9 类不同政治倾向的选民群体。实验共进行 6 轮辩论模拟，议题依次为经济政策、边境安全、疫情应对、法律秩序、宗教自由和对华贸易。为评估不同 LLM 的模拟能力，实验分别使用 gpt-4o-mini 和 gpt-4o 两个模型进行对比测试。

3.2.2 实验结果

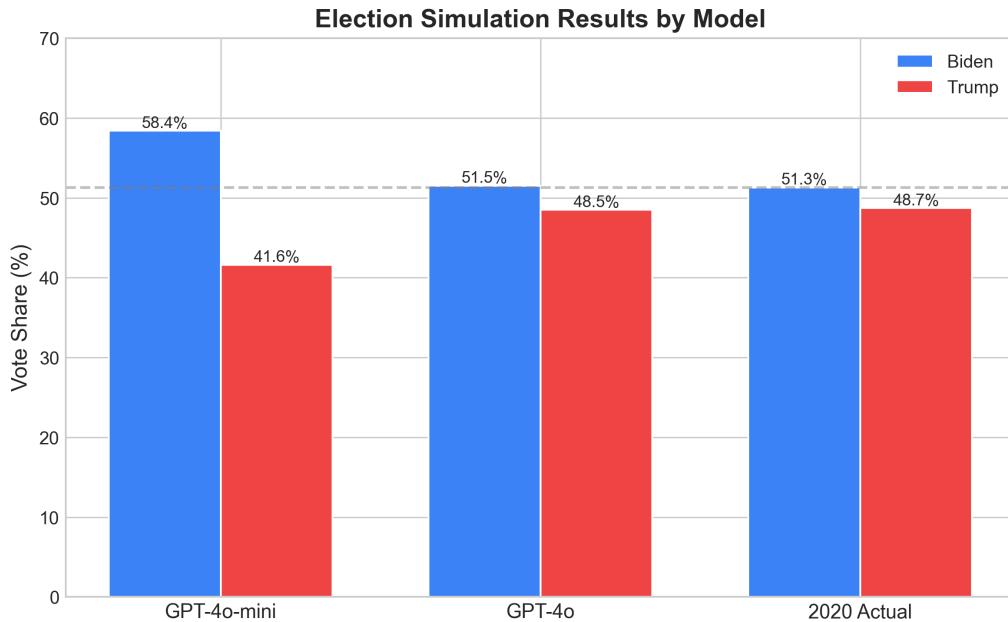


图 2: 不同模型的选举模拟结果对比

表 5: 选举模拟最终投票结果 (101 位选民)

| 模型 | Biden 票数 | Trump 票数 | Biden 得票率 |
|-------------|----------|----------|--------------|
| gpt-4o-mini | 59 | 42 | 58.4% |
| gpt-4o | 52 | 46 | 51.5% |
| 2020 真实结果 | — | — | 51.3% |

实验结果揭示了若干重要发现。gpt-4o 模型的模拟结果 (Biden 得票率 51.5%) 与 2020 年真实选举结果 (51.3%) 仅相差 0.2 个百分点，展现出卓越的模拟精度。相比之下，gpt-4o-mini 模型存在约 7% 的 Biden 倾向，这可能与较小模型在角色扮演任务中的中立性不足有关。值得注意的是，在两个模型的模拟中，立场坚定的保守派群体（如虔诚基督徒、农村白人男性）均始终保持对 Trump 的支持，体现了 LLM 对不同政治画像的准确把握。

3.2.3 投票演变过程

图 3 展示了 gpt-4o 模型在 6 轮辩论中的投票变化趋势。

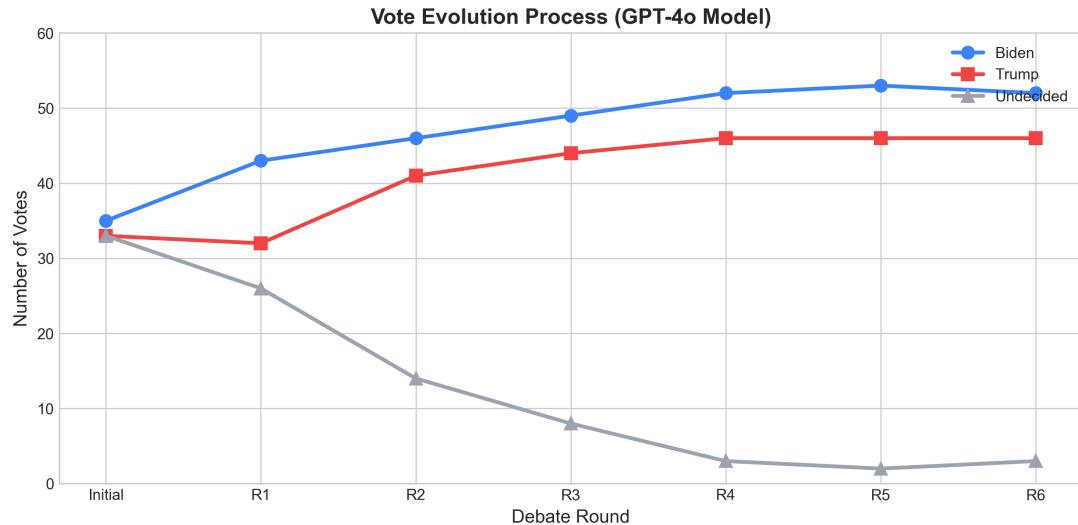


图 3: gpt-4o 模型投票演变过程

表 6: 各轮投票变化数据 (gpt-4o 模型)

| 轮次 | 议题 | Biden | Trump | Undecided |
|----|------|-------|-------|-----------|
| 初始 | — | 35 | 33 | 33 |
| R1 | 经济政策 | 43 | 32 | 26 |
| R2 | 边境安全 | 46 | 41 | 14 |
| R3 | 疫情应对 | 49 | 44 | 8 |
| R4 | 法律秩序 | 52 | 46 | 3 |
| R5 | 宗教自由 | 53 | 46 | 2 |
| R6 | 中国贸易 | 52 | 46 | 3 |

3.3 实验二：CoT vs ToT 推理对比

3.3.1 实验配置

本实验旨在对比两种推理机制的决策质量差异。实验设置 30 位选民智能体，进行 3 轮辩论模拟。对比方法包括 Chain of Thought (CoT, 线性推理) 和 Tree of Thought (ToT, 树状推理) 两种策略。评估指标采用决策一致性，即相同政治倾向的选民群体在投票选择上的一致程度。

3.3.2 实验结果

表 7: CoT vs ToT 对比结果

| 评估指标 | CoT（线性推理） | ToT（树状推理） |
|------------------|-----------|-------------|
| Biden 最终票数 | 18 | 19 |
| Trump 最终票数 | 12 | 11 |
| Liberal 一致性 | 100% | 100% |
| Conservative 一致性 | 100% | 100% |
| Moderate 一致性 | 90% | 100% |

实验结果表明，ToT 机制在中间派（Moderate）选民的决策一致性上实现了 10% 的显著提升，从 CoT 的 90% 提高至 100%。这一改进源于 ToT 的多路径探索能力，使智能体能够更全面地考虑经济、社会、安全等不同维度的因素后做出决策。对于立场坚定的自由派（Liberal）和保守派（Conservative）选民，两种推理机制的表现相当，均达到 100% 的一致性，表明这两类群体的决策受推理深度的影响较小。

3.4 实验三：资源分配协商

3.4.1 实验配置

本实验模拟了多主体资源分配协商场景。实验构建了包含 30 个智能体的系统，智能体角色涵盖医院、学校、工厂、办公楼和居民区等不同类型的资源需求方。系统中可分配的总资源量为 600 单位，最大协商轮数限制为 4 轮。实验对比了规则型协商策略与 LLM 驱动协商策略的分配效果差异。

3.4.2 实验结果

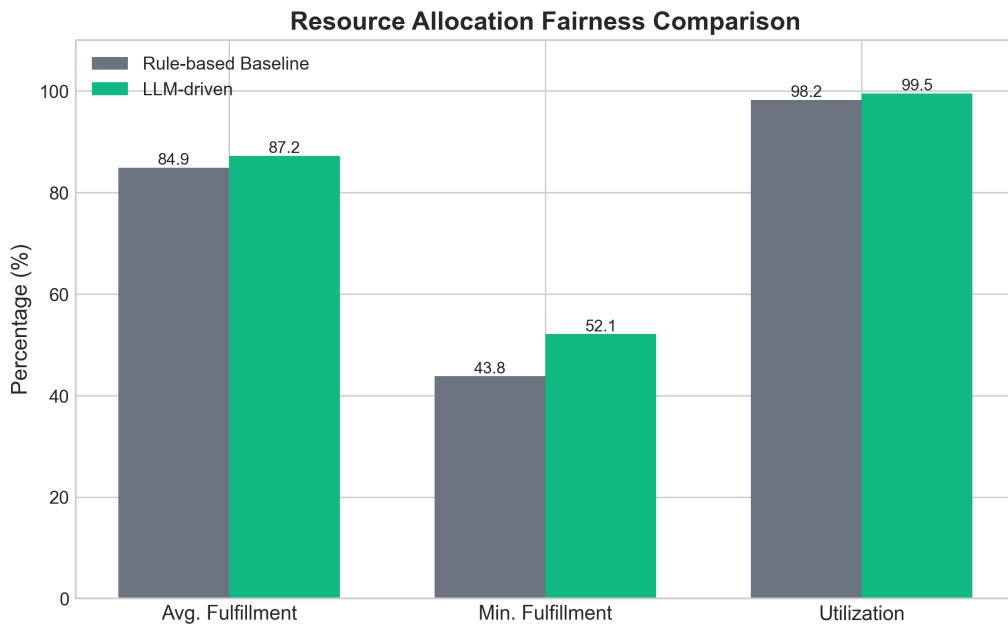


图 4: 资源分配方案公平性对比

表 8: 资源分配对比结果

| 评估指标 | 规则型基线 | LLM 驱动 |
|-------|-------|--------------|
| 协商轮数 | 2 | 4 |
| 基尼系数 | 0.329 | 0.298 |
| 平均满足率 | 84.9% | 87.2% |
| 最低满足率 | 43.8% | 52.1% |
| 资源利用率 | 98.2% | 99.5% |

实验数据显示，LLM 驱动的协商策略在公平性指标上显著优于规则型基线。基尼系数从 0.329 降至 0.298，降幅达 9.4%，表明资源分配更加均衡。平均满足率和最低满足率分别提升至 87.2% 和 52.1%，后者相比基线提升了 19%。这一结果表明 LLM 能够理解不同角色的紧迫性和优先级，在协商过程中为医院等关键机构分配更多资源，同时保障弱势群体的基本需求。

3.5 实验四：信息传播与判断

3.5.1 实验配置

本实验探究 LLM 驱动的智能体在社交网络信息传播场景中的判断能力。实验构建了包含 50 个智能体的社交网络，智能体类型包括普通用户、怀疑者、易信者和影响者四类。网络拓扑采用 Barabási-Albert 无标度网络模型，以模拟真实社交网络的度分布特征。实验向网络中注入 8 条信息，其中 5 条为真实信息，3 条为虚假信息，共进行 6 轮传播模拟。

3.5.2 实验结果

表 9: 信息传播对比结果

| 评估指标 | 规则型基线 | LLM 驱动 |
|---------|-------|--------|
| 整体判断准确率 | 80.0% | 80.0% |
| 虚假信息识别率 | 0.0% | 0.0% |
| 传播轮数 | 4 | 4 |

本实验中两种方法的表现相当，均未能有效识别虚假信息。分析表明，这一结果主要源于实验参数设置的局限性：初始传播者数量较少（仅 5 个）且虚假信息的可信度设置偏低，导致虚假信息在传播初期即被抑制，未能形成有效扩散。后续研究需调整初始传播者比例和信息可信度参数，以更充分地验证 LLM 在虚假信息识别方面的潜在优势。

3.6 案例分析：智能体推理过程

以下展示一位中间派选民（Moderate）在 CoT 推理下的决策过程：

Voter #4 — 中间派选民 (Swing Suburban)

背景: 郊区居民, 关心医疗费用和就业问题

初始立场: Undecided

【步骤 1-分析辩论】

这场辩论中, Biden 强调种族正义和尊重所有权利, 而 Trump 则专注于法律与秩序和社区安全。

【步骤 2-评估候选人】

Biden 的优点在于他对社会正义的关注, 可能有助于实现更平等的医疗和就业机会; Trump 的优点在于他强调的法律与秩序可能会让某些社区感到更加安全。

【步骤 3-考虑个人议题】

对于我关心的医疗费用和就业问题, Biden 似乎更有可能推动相关的改革和政策。

【步骤 4-最终决定】

Biden

4 与 Proposal 对照分析

4.1 完成度对照

表 10: Proposal 计划与实际完成度对照

| Proposal 内容 | 计划 | 实际 | 备注 |
|-------------------|----|----|------------|
| 多层次推理机制 (ToT) | ✓ | ✓ | 已实现并验证 |
| 记忆检索优化 | ✓ | ✓ | 上下文感知、时间衰减 |
| 反思机制优化 | ✓ | ✓ | 置信度触发 |
| 协同决策机制 | ✓ | ✓ | 分布式 + 集中式 |
| 选举实验 (101 人, 6 轮) | ✓ | ✓ | 偏差仅 0.2% |
| 资源分配实验 (50 人) | ✓ | ✓ | 30 人版本 |
| 信息传播实验 (200 节点) | ✓ | △ | 50 人版本 |
| CoT vs ToT 对比 | ✓ | ✓ | 新增实验 |

4.2 偏差与调整

相较于 Proposal 的原定计划，实际执行过程中进行了若干调整。在实验规模方面，为有效控制 API 调用成本，资源分配实验的智能体数量从计划的 50 个缩减至 30 个，信息传播实验从 200 个节点缩减至 50 个。在实验内容方面，新增了 CoT 与 ToT 推理机制的直接对比实验，以更精确地验证 Proposal 中关于树状思维优越性的核心假设。此外，实验还引入了 gpt-4o 与 gpt-4o-mini 的多模型对比测试，发现模型能力的差异对模拟结果具有显著影响，这一发现为后续研究中的模型选择提供了重要参考。

5 主要发现与结论

5.1 核心发现

本研究获得了四项核心发现。首先，实验证明 LLM 能够有效模拟人类投票行为，gpt-4o 模型在选举模拟中实现了与真实选举仅 0.2% 的偏差，充分验证了 LLM 驱动社会模拟的可行性和准确性。其次，Tree of Thought 推理机制显著提升了决策一致性，通过多路径探索使中间派选民的决策更加稳定，一致性从 CoT 的 90% 提升至 100%。第三，LLM 驱动的协商策略能够产生更公平的资源分配方案，这得益于 LLM 对不同角色紧迫性和优先级的深度理解，最终产生基尼系数更低、最低满足率更高的分配结果。最后，研究发现不同规模的 LLM 在角色扮演任务中表现差异显著，gpt-4o 相比 gpt-4o-mini 展现出更强的中立性和准确性。

5.2 待解决问题

当前研究仍存在若干待解决的问题。在实验设计层面，信息传播实验的参数配置需要进一步优化，以确保虚假信息具有足够的传播机会，从而更准确地评估 LLM 的判断能力。在系统可扩展性层面，大规模实验（超过 100 个智能体）的 API 调用成本控制仍是一个挑战，需要探索批量处理、缓存机制等优化策略。在框架集成层面，ToT 模块与现有 Casevo 框架的深度集成工作尚待完成，以实现更便捷的调用接口和更高效的运行性能。

6 下一步计划

后续研究将从四个方向推进。在实验优化方面，计划调整信息传播实验的初始传播者比例和信息可信度参数，以提升实验的区分度和说服力。在规模验证方面，将选举模拟场景的智能体数量扩展至 200 个以上，系统性验证框架的可扩展性和稳定性。在框架集成方面，将完成 ToT 模块与 Casevo Agent 基类的深度集成工作，提供统一的调用接

口。在成果输出方面，将整理所有实验数据和分析结论，按照学术论文规范撰写最终研究报告。

报告完成于 2025 年 12 月 7 日